Assignment 2 - DS4Biz Y63

TextScraping_Classification

Team Detail

Team Name: jonas

Student 1

Student ID: 61070296
Student Full Name: ณัฐวุฒิ อกนิษฐ์ศุภร

Student 2

Student ID: 61070319
Student Full Name: โรจนัสถ์ รอดรุ่งเรือง

Import Library

In [199]:
```
import requests
import bs4
from pprint import pprint
import pandas as pd
import numpy as np
import warnings
import nltk
import matplotlib.pyplot as plt
from sklearn.feature_extraction.text import CountVectorizer
from sklearn.preprocessing import LabelEncoder
from sklearn.model_selection import train_test_split
from sklearn.feature_extraction.text import TfidfVectorizer
from sklearn.metrics import mean_absolute_error
from sklearn.metrics import mean_squared_error
from sklearn.metrics import r2_score
from sklearn.metrics import recall_score, precision_score,f1_score
from numpy import mean
from numpy import std
from sklearn.datasets import make_classification
from sklearn.model_selection import cross_val_score
from sklearn.model_selection import KFold
from sklearn.model_selection import GridSearchCV
from sklearn.ensemble import RandomForestClassifier
warnings.filterwarnings('ignore')
```

Scraping Websites

ทำการ Scraping หน้าเว็บเพื่อเอาข้อมูลของแต่ละข่าวมาทำการทำนายประเภทของแต่ละข่าว

Function scraping web

In [2]:
```
def month(link,target):#เป็นฟังชั้นที่ใช้ Scraping ของหน้าแต่ละเดือนเพื่อเอาข้อมูล Target
    response = requests.get(link)
    html_page = bs4.BeautifulSoup(response.content, 'html.parser')
    selector = "body > div > div.main > table > tbody > tr > td.category"#เลือกตารางในส่วนของเฉพาะ Category
    tag = html_page.select(selector)
    for i in tag:
        target.append(i.text.strip())# นำข้อมูลของแต่ละ Category มาเพิ่มเข้าตาราง Target

def news(link,links,des):#เป็นฟังชั้นที่ใช้ Scraping ของหน้าแต่ละเดือนเพื่อเอาข้อมูล Links ของแต่ละข่าวเพื่อนำไปเข้าสู่เนื้อหาของแต่ละข่าว
    response = requests.get(link)
    html_page = bs4.BeautifulSoup(response.content, 'html.parser')
    selector = "body > div > div.main > table > tbody > tr > td.title > a"#เลือกตารางในส่วนของเฉพาะ a
    tag = html_page.select(selector)
    for i in tag:
#         print(i['href'])
        links.append(i['href'])# นำข้อมูลของแต่ละ Category มาเพิ่มเข้าตาราง links
        descrip('http://www.it.kmitl.ac.th/~teerapong/news_archive/' + i['href'], des)#นำข้อมูลของ Links มาเชื่อมต่อเข้าสู่เนื้อหาของแต่ละข่าว

def descrip(link,des):#เป็นฟังชั้นที่ใช้ Scraping ของหน้าแต่ละเดือนเพื่อเอาข้อมูล Links ของแต่ละข่าวเพื่อนำไปเข้าสู่เนื้อหาของแต่ละข่าว
    text = ""
    response = requests.get(link)
    html_page = bs4.BeautifulSoup(response.content, 'html.parser')
    selector = "body > div > div.main > h2"#เลือกหัวข้อข่าวของ Tag h2
    tag = html_page.select_one(selector)
#     text = text + tag.text + " " เป็นการ Scraping หัวข้อข่าวมาเก็บเข้า String Text

    response = requests.get(link)
    html_page = bs4.BeautifulSoup(response.content, 'html.parser')
    selector = "body > div > div.main > p"  #เลือกเนื้อหาข่าวของ Tag p
    tag2 = html_page.select(selector)
    for i in tag2:# Loop เพื่อดูข้อมูลของแต่ละเนื้อหาข่าวเพื่อนำมาเช็คเงื่อนไข
#         print(i.text)
        if i.text == tag.text:# ตักเพื่อดูว่าบางเนื้อหาข่าวมีชื่อหัวข้อข่าวมาซ้ำกับของ Tag h2 จึงไม่ทำการเพิ่ม
            continue
        elif i.text in ['Return to article search results','Comments are closed for this article.']:# ตักเพื่อไม่ให้นำประโยคนี้ไปใช้ในการทำนายประเภทข่าว
            continue
        else:
            text = text + i.text# เพิ่มเนื้อหาที่ได้เข้าสู่ String Text เพื่อนำไป Save ลง File
    des.append(text.strip())# นำ String ที่ต่อกันแล้วมาลบช่องว่างระหว่างหน้าหลังด้วย Strip() แล้วทำการเพิ่มเข้า List Des
```

In [98]:
```
response = requests.get('http://www.it.kmitl.ac.th/~teerapong/news_archive/index.html')
html_page = bs4.BeautifulSoup(response.content, 'html.parser')
selector = "body > div.container > div.main > ul > li > a"# ดูข้อมูลของหน้า Index เพื่อเข้าแต่ละ Links ของแต่ละเดือน
tag = html_page.select(selector)
target = [] # List ของ Category ของแต่ละข่าว
des = [] # List คำอธิบายของแต่ละข่าว
```

```
links = [] # List ชื่อ Links ของแต่ละข่าว
for i in tag:
    month('http://www.it.kmitl.ac.th/~teerapong/news_archive/' + i['href'],target)
    news('http://www.it.kmitl.ac.th/~teerapong/news_archive/' + i['href'], links , des)
```

Save data in text file

In [16]:
```
newwwww = [] #List Category ที่ผ่านการกรองแล้ว
text_target = ""
for i in target:
    if i == 'N/A': #ถ้า Category เป็น N/A จะไม่ทำการเพิ่มเข้า List newwwww
        continue
    else:
        newwwww.append(i)
        text_target = text_target + i.strip() + "\n" #ทำการตัดช่องว่างและเพิ่มขึ้นบรรทัดใหม่ให้แต่ละ Category
f = open("target.txt", "w",encoding ='utf-8')
f.write(text_target.strip()) # Save เข้าไฟล์ที่ชื่อ target.txt
f.close()
```

In [7]:
```
text_links = ""
for i in links:
    text_links = text_links + i.strip() + "\n" #ทำการตัดช่องว่างและเพิ่มขึ้นบรรทัดใหม่ให้แต่ละ Links
f = open("links.txt", "w",encoding ='utf-8')
f.write(text_links.strip()) # Save เข้าไฟล์ที่ชื่อ links.txt
f.close()
```

In [100]:
```
text_des = ""
for i in des:
    text_des = text_des + i.strip() + "\n" #ทำการตัดช่องว่างและเพิ่มขึ้นบรรทัดใหม่ให้แต่ละเนื้อหาข่าว
f = open("contentwithoutheader.txt", "w",encoding ='utf-8')
f.write(text_des.strip())  # Save เข้าไฟล์ที่ชื่อ desnohead.txt
f.close()
```

Load data without header File

โหลดข้อมูลที่ทำการเก็บแบบไม่มีหัวข้อของแต่ละข่าว

In [306]:
```
f = open('target.txt','r',encoding='utf-8') # Load ไฟล์ Target
target = [] # List แต่ละ Category
for i in f:
    target.append(i.strip())
f.close()
y = target # เซ็ตค่า y ให้เป็นList ของแต่ละ Category
```

In [307]:
```
f = open('contentwithoutheader.txt','r',encoding='utf-8') # Load ไฟล์ des ที่ไม่มีหัวข้อข่าว
data = [] # List ของเนื้อหาของแต่ละข่าว
for i in f:
    data.append(i.strip())
f.close()
```

Create DataFrame

ทำการสร้าง DataFrame เพื่อจับคู่เนื้อหาของข่าวกับ Category ของข่าวนั้นๆ

In [238]:
```
df =  pd.DataFrame({'Des' : data, 'Target' : target}) #สร้าง Dataframe โดยมี Column Des กับ Target ของแต่ละข่าว
df
```

Out[238]:

	Des	Target
0	The sporting industry has come a long way sinc...	technology
1	Shares in Europe's leading reinsurers and trav...	business
2	BT is offering customers free internet telepho...	technology
3	Shares in UK banking group Barclays have risen...	business
4	England centre Olly Barkley has been passed fi...	sport
...	...	...
1403	Toulouse's former Irish international Trevor B...	sport
1404	The trial of Bernie Ebbers, former chief execu...	business
1405	Russian oil firm Yukos lied to a US court in a...	business
1406	Russian oil company Yukos has dropped the thre...	business
1407	Zambia's technical director, Kalusha Bwalya is...	sport

1408 rows × 2 columns

In [239]:
```
len(data)
```

Out[239]: 1408

In [240]:
```
data[1]
```

Out[240]:
'Shares in Europe\'s leading reinsurers and travel firms have fallen as the scale of the damage wrought by tsunamis across south Asia has become apparent. More than 23,000 people have been killed following a massive underwater earthquake and many of the worst hit areas are popular tourist destinations. Reis urance firms such as Swiss Re and Munich Re lost value as investors worried about rebuilding costs. But the disaster has little impact on stock markets in the US and Asia.Currencies including the Thai baht and Indonesian rupiah weakened as analysts warned that economic growth may slow. "It came at the worst possible time," said Hans Goetti, a Singapore-based fund manager. "The impact on the tourist industry is pretty devastating, especially in Thailand." Travel-r elated shares dropped in Europe, with companies such as Germany\'s TUI and Lufthansa and France\'s Club Mediterranne sliding. Insurers and reinsurance f irms were also under pressure in Europe.Shares in Munich Re and Swiss Re - the world\'s two biggest reinsurers - both fell 1.7% as the market speculated a bout the cost of rebuilding in Asia. Zurich Financial, Allianz and Axa also suffered a decline in value.However, their losses were much smaller, reflecting the market\'s view that reinsurers were likely to pick up the bulk of the costs. Worries about the size of insurance liabilities dragged European shares down, alth ough the impact was exacerbated by light post-Christmas trading. Germany\'s benchmark Dax index closed the day 16.29 points lower at 3.817.69 while Fra nce\'s Cac index of leading shares fell 5.07 points to 3.817.69. Investors pointed out, however, that declines probably would be industry specific, with the tra vel and insurance firms hit hardest. "It\'s still too early for concrete damage figures," Swiss Re\'s spokesman Floiran Woest told Associated Press. "That also has to do with the fact that the damage is very widely spread geographically."The unfolding scale of the disaster in south Asia had little immediate impact on US shares, however. The Dow Jones index had risen 20.54 points, or 0.2%, to 10,847.66 by late morning as analsyts were cheered by more encouraging re ports from retailers about post-Christmas sales. In Asian markets, adjustments were made quickly to account for lower earnings and the cost of repairs. Thai Airways shed almost 4%. The country relies on tourism for about 6% of its total economy. Singapore Airlines dropped 2.6%. About 5% of Singapore\'s annu al gross domestic product (GDP) comes from tourism. Malaysia\'s budget airline, AirAsia fell 2.9%. Resort operator Tanco Holdings slumped 5%.Travel comp anies also took a hit, with Japan\'s Kinki Nippon sliding 1.5% and HIS dropping 3.3%. However, the overall impact on Asia\'s largest stock market, Japan\'s Nikkei, was slight. Shares fell just 0.03%. Concerns about the strength of economic growth going forward weighed on the currency markets. The Indonesian rupiah lost as much as 0.6% against the US dollar, before bouncing back slightly to trade at 9,300. The Thai baht lost 0.3% against the US currency, trading at 39.10. In India, where more than 2,000 people are thought to have died, the rupee shed 0.1% against the dollar Analysts said that it was difficult to predi ct the total cost of the disaster and warned that share prices and currencies would come under increasing pressure as the bills mounted.'

Text Preprocessing

Function Tokenizer

In [241]:
```
from sklearn.feature_extraction import text
stopwords = text.ENGLISH_STOP_WORDS#เป็นการdownload คำstopword
def stopword(texts): #เป็น function ในการลบเอาstopword ออกจากtokenในตัวข้อมูลของเรา
    standard_tokenizer = CountVectorizer().build_tokenizer()#เป็นการสร้างfunctionในการสร้างtoken
    tokens = standard_tokenizer(texts)#เป็นการนำข้อมูล quotesมาทำการตัดคำ
    text_tokens = []#list ที่ใช้เก็บคำที่ไม่มีstopwordอยู่ในนั้นเพื่อเตรียมเอาเข้าbag of word
    for token in tokens: #loop เพื่อดึงคำจากที่เราทำtokenไว้เพื่อนำไปเช็คว่าคำไหนเป็นstop word
        if not token in stopwords: #เงื่อนไขที่เอาไว้check ว่าคำไหนไม่ใช่stop word
            text_tokens.append(token)#เก็บคำที่ไม่ใช่stop wordไว้ในlist
    return text_tokens
def lemma_tokenizer(tokens):
    lemmatizer = nltk.stem.WordNetLemmatizer() #เป็นการสร้างfunction ในการแปลงคำ
    lemma_tokens = [] #listที่เก็บคำหลังจากที่แปลงผ่านfunctionแล้ว
    for token in tokens:  #loopเพื่อที่จะเอาคำไปแปลง
        lemma_tokens.append( lemmatizer.lemmatize(token)) #เป็นการแปลงคำศัพท์และนำเก็บลงlist lemma_tokens
    return lemma_tokens
```

Filter Stopword

ทำการตัดคำ Stopword เช่น Is am are เนื่องจากเป็นคำที่ไม่สามารถนำมาใช้ในการทำนายได้จึงทำการ Loop เพื่อลบศัพท์เหล่านั้น

In [258]:
```
count = 0
for i in data:
    token = stopword(i)  # นำเนื้อหาข่าวเข้าฟังชั้น stopword เพื่อทำการตัดคำ Stopword
    lemma = lemma_tokenizer(token) # นำเข้าฟังชั้น Lemme_tokenizer เพื่อทำการแปลงคำ
    text = ''
    for word in lemma: # นำคำศัพท์ที่ผ่านการแปลงคำมาแล้วมาแทนคำ Data เก่าที่ไม่ได้ทำการตัดคำ Stopword
        text += word + ' '
    data[count]= text
    count += 1
```

In [259]:
```
data
```

Out[259]:
```
['The sporting industry come long way 60 It carved niche root deep fathom sport industry showing sign decline time soon later The reason seemingly subt
le difference industry customer sporting industry fan Vivek Ranadivé leader ownership group NBA Sacramento Kings explained beautifully Fans paint face
purple fan evangelize Every CEO business dying position dying fan While fan passion certainly industry going league sporting franchise decided rest laurel
The year seen steady introduction technology world sport amplifying fan appreciation game enhancing athlete public profile informing training method infl
uencing contest waged Also digital technology particular helped create alternative source revenue game corporate sponsorship They achieved capitalizing
ardor customer base sorry fan base ',
 'Shares Europe leading reinsurers travel firm fallen scale damage wrought tsunami south Asia apparent More 23 000 people killed following massive unde
rwater earthquake worst hit area popular tourist destination Reisurance firm Swiss Re Munich Re lost value investor worried rebuilding cost But disaster lit
tle impact stock market US Asia Currencies including Thai baht Indonesian rupiah weakened analyst warned economic growth slow It came worst possible
time said Hans Goetti Singapore based fund manager The impact tourist industry pretty devastating especially Thailand Travel related share dropped Euro
pe company Germany TUI Lufthansa France Club Mediterranne sliding Insurers reinsurance firm pressure Europe Shares Munich Re Swiss Re world bigges
t reinsurers fell market speculated cost rebuilding Asia Zurich Financial Allianz Axa suffered decline value However loss smaller reflecting market view rein
surers likely pick bulk cost Worries size insurance liability dragged European share impact exacerbated light post Christmas trading Germany benchmark D
ax index closed day 16 29 point lower 817 69 France Cac index leading share fell 07 point 817 69 Investors pointed decline probably industry specific trav
el insurance firm hit hardest It early concrete damage figure Swiss Re spokesman Floiran Woest told Associated Press That fact damage widely spread ge
ographically The unfolding scale disaster south Asia little immediate impact US share The Dow Jones index risen 20 54 point 10 847 66 late morning anals
yts cheered encouraging report retailer post Christmas sale In Asian market adjustment quickly account lower earnings cost repair Thai Airways shed The
country relies tourism total economy Singapore Airlines dropped About Singapore annual gross domestic product GDP come tourism Malaysia budget airlin
e AirAsia fell Resort operator Tanco Holdings slumped Travel company took hit Japan Kinki Nippon sliding HIS dropping However overall impact Asia large
```

In [260]:
```
vectorizer = TfidfVectorizer(min_df = 10) # เป็นการเลือกความถี่ของแต่ละคำศัพท์ว่ามีความถี่มากกว่า 10 หรือไม่ถ้าน้อยกว่า 10 จะไม่นำมาใช้ในการทำ Model
X = vectorizer.fit_transform(data)
print(X.shape)
```

```
(1408, 3801)
```

Data Without Header Model

ในการทำ Model ของข้อมูลนี้เป็นการทำนายแบบ Multi-class จึงเลือกใช้ Model Logistic Regression ,Naive Bayes และ Support Vector Machines (SVM) โดยในส่วนของ Naive Bayes นั้นมีอีก 2 Model ที่สามารถทำนายแบบ Multi-class ได้คือ BernoulliNB และ MultinomialNB โดยการทำ Model ทั้งหมดจะทำแบบ Nested Cross Validation เพื่อทำการ Tune Parameter ของแต่ละ Model เพื่อให้ได้ Model ที่เหมาะสมที่สุด

Logistic Regression

In [280]:
```
Bar_y_without_header = [] # List ที่ไว้เก็บค่า Accuracy ของแต่ละ Model
```

In [281]:
```
from sklearn.linear_model import LogisticRegression
cv_inner = KFold(n_splits=3, random_state=1) #เลือกรอบCross Validate รอบใน
model = LogisticRegression()
space = dict() # ไว้เลือก Parameter เพื่อทำการ Tune
space['solver'] = ['newton-cg', 'lbfgs', 'liblinear', 'sag', 'saga']
space['C'] = [0.1, 1, 10]
search = GridSearchCV(model, space, scoring='accuracy', n_jobs=1, cv=cv_inner, refit=True) # ทำการสร้าง Model ที่ใช้ในการ Tune Parameter
cv_outer = KFold(n_splits=10, random_state=1) #เลือกรอบ Cross Validate รอบนอก
scores = cross_val_score(search, X, y, scoring='accuracy', cv=cv_outer, n_jobs=-1) # ทำ Cross Validate โดยใช้ Model ของ GridSearchCV เพื่อคา Parameter ท
print('Accuracy: %.2f %s' % (mean(scores)*100, '%'))
Bar_y_without_header.append(float("%.2f" %(mean(scores)*100))) # นำค่า Accuracy เข้าตาราง Bar_y_without_header
```

```
Accuracy: 98.08 %
```

In [282]:
```
search.fit(X,y)
search.best_params_
```

Out[282]:
```
{'C': 10, 'solver': 'newton-cg'}
```

โดยค่า Parameter ที่ดีที่สุดคือ C = 10 และ Solver เป็น newton-cg

Naive Bayes BernoulliNB

In [283]:
```
from sklearn.naive_bayes import BernoulliNB
cv_inner = KFold(n_splits=3, shuffle=True, random_state=1)
model = BernoulliNB()
space = dict()
space['alpha'] = [0.0, 0.0001, 0.001, 0.01, 0.1, 0.5, 1.0, 2.0, 10.0]
space['fit_prior'] = ['TRUE','FALSE']
search = GridSearchCV(model, space, scoring='accuracy', n_jobs=1, cv=cv_inner, refit=True)
cv_outer = KFold(n_splits=10, shuffle=True, random_state=1)
scores = cross_val_score(search, X, y, scoring='accuracy', cv=cv_outer, n_jobs=-1)
print('Accuracy: %.2f %s' % (mean(scores)*100, '%'))
Bar_y_without_header.append(float("%.2f" %(mean(scores)*100)))
```

```
Accuracy: 97.80 %
```

In [284]:
```
search.fit(X,y)
search.best_params_
```

Out[284]: {'alpha': 0.01, 'fit_prior': 'TRUE'}

โดยค่า Parameter ที่ดีที่สุดคือ alpha = 0.01 และ fit_prior เป็น TRUE

Naive Bayes MultinomialNB

In [285]:
```
from sklearn.naive_bayes import MultinomialNB
cv_inner = KFold(n_splits=3, shuffle=True, random_state=1)
model = MultinomialNB()
space = dict()
space['alpha'] = [0.0, 0.0001, 0.001, 0.01, 0.1, 0.5, 1.0, 2.0, 10.0]
space['fit_prior'] = ['TRUE','FALSE']
search = GridSearchCV(model, space, scoring='accuracy', n_jobs=1, cv=cv_inner, refit=True)
cv_outer = KFold(n_splits=10, shuffle=True, random_state=1)
scores = cross_val_score(search, X, y, scoring='accuracy', cv=cv_outer, n_jobs=-1)
print('Accuracy: %.2f %s' % (mean(scores)*100, '%'))
Bar_y_without_header.append(float("%.2f" %(mean(scores)*100)))
```

Accuracy: 97.94 %

In [286]:
```
search.fit(X,y)
search.best_params_
```

Out[286]: {'alpha': 0.5, 'fit_prior': 'TRUE'}

โดยค่า Parameter ที่ดีที่สุดคือ alpha = 0.5 และ fit_prior เป็น TRUE

Support Vector Machines (SVM)

In [287]:
```
from sklearn import svm
cv_inner = KFold(n_splits=3, shuffle=True, random_state=1)
model =svm.SVC()
space = dict()
space['gamma'] = [1, 0.1, 0.01]
space['C'] = [0.1, 1, 10]
search = GridSearchCV(model, space, scoring='accuracy', n_jobs=1, cv=cv_inner, refit=True)
cv_outer = KFold(n_splits=10, shuffle=True, random_state=1)
scores = cross_val_score(search, X, y, scoring='accuracy', cv=cv_outer, n_jobs=-1)
print('Accuracy: %.2f %s' % (mean(scores)*100, '%'))
Bar_y_without_header.append(float("%.2f" %(mean(scores)*100)))
```

Accuracy: 98.44 %

In [288]:
```
search.fit(X,y)
search.best_params_
```

Out[288]: {'C': 10, 'gamma': 0.1}

โดยค่า Parameter ที่ดีที่สุดคือ C = 10 และ gamma เป็น 0.1

Load Data With Header

ทำการทำนาย Category ด้วยข้อมูลที่มีหัวข้อของแต่ละข่าว

In [310]:
```
f = open('contentwithheader.txt','r',encoding='utf-8')
data = []
for i in f:
    data.append(i.strip())
f.close()
```

Create DataFrame

In [290]:
```
df =  pd.DataFrame({'Des' : data, 'Target' : target})
df
```

Out[290]:

	Des	Target
0	21st-Century Sports: How Digital Technology Is...	technology
1	Asian quake hits European shares Shares in Eur...	business
2	BT offers free net phone calls BT is offering ...	technology
3	Barclays shares up on merger talk Shares in UK...	business
4	Barkley fit for match in Ireland England centr...	sport
...	...	...
1403	Woodward eyes Brennan for Lions Toulouse's for...	sport
1404	WorldCom trial starts in New York The trial of...	business
1405	Yukos accused of lying to court Russian oil fi...	business
1406	Yukos drops banks from court bid Russian oil c...	business
1407	Zambia confident and cautious Zambia's technic...	sport

1408 rows × 2 columns

In [291]:
```
len(data)
```

Out[291]: 1408

In [292]:
```
data[1]
```

Out[292]: 'Asian quake hits European shares Shares in Europe\'s leading reinsurers and travel firms have fallen as the scale of the damage wrought by tsunamis across south Asia has become apparent.More than 23,000 people have been killed following a massive underwater earthquake and many of the worst hit areas are popular tourist destinations. Reisurance firms such as Swiss Re and Munich Re lost value as investors worried about rebuilding costs. But the disaster has littl e impact on stock markets in the US and Asia.Currencies including the Thai baht and Indonesian rupiah weakened as analysts warned that economic growth may slow. "It came at the worst possible time," said Hans Goetti, a Singapore-based fund manager. "The impact on the tourist industry is pretty devastating, especially in Thailand." Travel-related shares dropped in Europe, with companies such as Germany\'s TUI and Lufthansa and France\'s Club Mediterranne sli ding. Insurers and reinsurance firms were also under pressure in Europe.Shares in Munich Re and Swiss Re - the world\'s two biggest reinsurers - both fell 1.7% as the market speculated about the cost of rebuilding in Asia. Zurich Financial, Allianz and Axa also suffered a decline in value.However, their losses w ere much smaller, reflecting the market\'s view that reinsurers were likely to pick up the bulk of the costs. Worries about the size of insurance liabilities drag ged European shares down, although the impact was exacerbated by light post-Christmas trading. Germany\'s benchmark Dax index closed the day 16.29 p oints lower at 3.817.69 while France\'s Cac index of leading shares fell 5.07 points to 3.817.69. Investors pointed out, however, that declines probably would be industry specific, with the travel and insurance firms hit hardest. "It\'s still too early for concrete damage figures," Swiss Re\'s spokesman Floiran Woest t old Associated Press. "That also has to do with the fact that the damage is very widely spread geographically."The unfolding scale of the disaster in south As ia had little immediate impact on US shares, however. The Dow Jones index had risen 20.54 points, or 0.2%, to 10,847.66 by late morning as analsyts were

cheered by more encouraging reports from retailers about post-Christmas sales. In Asian markets, adjustments were made quickly to account for lower earni ngs and the cost of repairs. Thai Airways shed almost 4%. The country relies on tourism for about 6% of its total economy. Singapore Airlines dropped 2. 6%. About 5% of Singapore\'s annual gross domestic product (GDP) comes from tourism. Malaysia\'s budget airline, AirAsia fell 2.9%. Resort operator Tanc o Holdings slumped 5%.Travel companies also took a hit, with Japan\'s Kinki Nippon sliding 1.5% and HIS dropping 3.3%. However, the overall impact on A sia\'s largest stock market, Japan\'s Nikkei, was slight. Shares fell just 0.03%. Concerns about the strength of economic growth going forward weighed on th e currency markets. The Indonesian rupiah lost as much as 0.6% against the US dollar, before bouncing back slightly to trade at 9,300. The Thai baht lost 0. 3% against the US currency, trading at 39.10. In India, where more than 2,000 people are thought to have died, the rupee shed 0.1% against the dollar An alysts said that it was difficult to predict the total cost of the disaster and warned that share prices and currencies would come under increasing pressure as the bills mounted.'

Text Preprocessing

Filter Stopword

In [293]:
```
count = 0
for i in data:
    token = stopword(i)
    text = ''
    for word in token:
        text += word + ' '
    data[count]= text
    count += 1
```

In [294]:
```
vectorizer = TfidfVectorizer(min_df = 10)
X = vectorizer.fit_transform(data)
print(X.shape)
```

```
(1408, 4156)
```

Data With Header Model

Logistic Regression

In [295]:
```
Bar_y_with_header = []
```

In [296]:
```
from sklearn.linear_model import LogisticRegression
cv_inner = KFold(n_splits=3, random_state=1)
model = LogisticRegression()
space = dict()
space['solver'] = ['newton-cg', 'lbfgs', 'liblinear', 'sag', 'saga']
space['C'] = [0.1, 1, 10]
search = GridSearchCV(model, space, scoring='accuracy', n_jobs=1, cv=cv_inner, refit=True)
cv_outer = KFold(n_splits=10, random_state=1)
scores = cross_val_score(search, X, y, scoring='accuracy', cv=cv_outer, n_jobs=-1)
print('Accuracy: %.2f %s' % (mean(scores)*100, '%'))
Bar_y_with_header.append(float("%.2f" %(mean(scores)*100)))
```

```
Accuracy: 98.29 %
```

In [297]:
```
search.fit(X,y)
search.best_params_
```

Out[297]:
```
{'C': 10, 'solver': 'newton-cg'}
```

โดยค่า Parameter ที่ดีที่สุดคือ C = 10 และ solver เป็น newton-cg

Naive Bayes BernoulliNB

In [298]:
```
from sklearn.naive_bayes import BernoulliNB
cv_inner = KFold(n_splits=3, shuffle=True, random_state=1)
model = BernoulliNB()
space = dict()
space['alpha'] = [0.0, 0.0001, 0.001, 0.01, 0.1, 0.5, 1.0, 2.0, 10.0]
space['fit_prior'] = ['TRUE','FALSE']
search = GridSearchCV(model, space, scoring='accuracy', n_jobs=1, cv=cv_inner, refit=True)
cv_outer = KFold(n_splits=10, shuffle=True, random_state=1)
scores = cross_val_score(search, X, y, scoring='accuracy', cv=cv_outer, n_jobs=-1)
print('Accuracy: %.2f %s' % (mean(scores)*100, '%'))
Bar_y_with_header.append(float("%.2f" %(mean(scores)*100)))
```

```
Accuracy: 97.87 %
```

In [299]:
```
search.fit(X,y)
search.best_params_
```

Out[299]:
```
{'alpha': 0.1, 'fit_prior': 'TRUE'}
```

โดยค่า Parameter ที่ดีที่สุดคือ alpha = 0.01 และ fit_prior เป็น TRUE

Naive Bayes MultinomialNB

In [300]:
```
from sklearn.naive_bayes import MultinomialNB
cv_inner = KFold(n_splits=3, shuffle=True, random_state=1)
model = MultinomialNB()
space = dict()
space['alpha'] = [0.0, 0.0001, 0.001, 0.01, 0.1, 0.5, 1.0, 2.0, 10.0]
space['fit_prior'] = ['TRUE','FALSE']
search = GridSearchCV(model, space, scoring='accuracy', n_jobs=1, cv=cv_inner, refit=True)
cv_outer = KFold(n_splits=10, shuffle=True, random_state=1)
scores = cross_val_score(search, X, y, scoring='accuracy', cv=cv_outer, n_jobs=-1)
print('Accuracy: %.2f %s' % (mean(scores)*100, '%'))
Bar_y_with_header.append(float("%.2f" %(mean(scores)*100)))
```

```
Accuracy: 97.73 %
```

In [301]:
```
search.fit(X,y)
search.best_params_
```

Out[301]:
```
{'alpha': 0.1, 'fit_prior': 'TRUE'}
```

โดยค่า Parameter ที่ดีที่สุดคือ alpha = 0.01 และ fit_prior เป็น TRUE

Support Vector Machines (SVM)

In [302]:
```
from sklearn import svm
cv_inner = KFold(n_splits=3, shuffle=True, random_state=1)
```

```
model =svm.SVC()
space = dict()
space['gamma'] = [1, 0.1, 0.01]
space['C'] = [0.1, 1, 10]
search = GridSearchCV(model, space, scoring='accuracy', n_jobs=1, cv=cv_inner, refit=True)
cv_outer = KFold(n_splits=10, shuffle=True, random_state=1)
scores = cross_val_score(search, X, y, scoring='accuracy', cv=cv_outer, n_jobs=-1)
print('Accuracy: %.2f %s' % (mean(scores)*100, '%'))
Bar_y_with_header.append(float("%.2f" %(mean(scores)*100)))
```

Accuracy: 98.44 %

In [303]:
```
search.fit(X,y)
search.best_params_
```

Out[303]:
```
{'C': 10, 'gamma': 0.1}
```

โดยค่า Parameter ที่ดีที่สุดคือ C = 10 และ gamma เป็น 0.1

Summary

In [305]:
```
Bar_x = ['Logistic Regression','BernoulliNB','MultinomialNB','Support Vector Machines (SVM)']
x = np.arange(len(Bar_x))
width = 0.35

fig, ax = plt.subplots(figsize=(10, 10))
rects1 = ax.bar(x - width/2, Bar_y_without_header, width, label='Without Header')
rects2 = ax.bar(x + width/2, Bar_y_with_header, width, label='With Header')
plt.grid()
plt.ylim(95,100)

ax.set_ylabel('Accuracy Scores')
ax.set_title('Accuracy Scores by With Header and Without Header')
ax.set_xticks(x)
ax.set_xticklabels(Bar_x)
ax.legend()

fig.tight_layout()
```

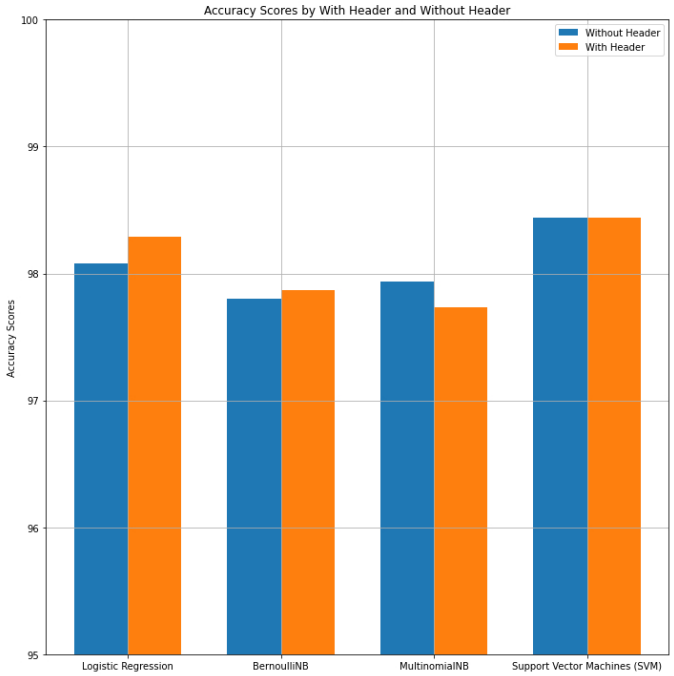

จากกราฟด้านบนจะเห็นได้ว่า Model ที่ผ่านการทำ Nested Cross Validation เพื่อทำการ Tune Parameter มาแล้ว โดยจะเห็นว่า Model แบบSupport Vector Machines (SVM) นั้นมีค่าความแม่นยำที่สุดทั้งข้อมูลแบบมีหัวข้อข่าวและข้อมูลที่ไม่มีหัวข้อข่าวแต่เมื่อดู Model อื่นๆจะเห็นว่า Logistic Regression และ Naive Bayes แบบ BernoulliNB นั้นในส่วนของข้อมูลแบบมีหัวข้อข่าวนั้นมีค่า Accuracy มากกว่าแบบไม่มีหัวข้อข่าว

สรุปได้ว่า Model ของ Support Vector Machines (SVM) ได้ค่า Accuracy มากที่สุด และข้อมูลที่ได้ค่า Accuracy มากที่สุดคือข้อมูลที่มีหัวข้อข่าวจึงสรุปได้ว่า Model ที่ดีที่สุดคือ Model Support Vector Machines (SVM) และใช้ข้อมูลแบบมีหัวข้อข่าวเพื่อให้ได้ค่า Accuracy ที่มากที่สุด